

Guion de exposición: K-Means

Qué hace cada casilla del notebook

`Tarea_KMeans_Descubriendo_patrones.ipynb` y qué decir en voz alta mientras la muestras.

En 60 segundos

Si solo tienes un minuto, esto es todo el trabajo.

Tengo datos de 18 estudiantes con dos variables: horas de estudio por semana y promedio académico. Nadie me dijo quién es bueno o malo: no hay etiquetas.

Le pedí a K-Means que encontrara 3 grupos. El algoritmo los halló solo, y quedaron perfectamente parejos: 6 estudiantes en cada grupo, que corresponden a bajo, medio y alto rendimiento.

Después inventé un estudiante nuevo, Mateo Andrade, con 18 horas y promedio 8.7. El modelo midió su distancia a los tres centros y lo mandó al grupo de alto rendimiento, porque ese centro está a 3.55 de distancia y el siguiente a 4.57.

Finalmente comparé K=2, K=3 y K=4. K=3 gana: tiene el mejor coeficiente de silueta (0.667) y es donde se forma el codo de la gráfica de inercia.

Cifras que debes tener en la cabeza

Si te preguntan un número, sale de aquí.

18

estudiantes (el mínimo pedido era 15)

2

variables: horas y promedio

3

grupos, de 6 estudiantes cada uno

55.43

inercia con K=3

0.667

silueta con K=3 (la más alta)

42

`random_state` : los resultados no cambian al reejecutar

Cómo funciona K-Means, en cuatro pasos

Esta es la explicación que sostiene todo lo demás. Apréndela como una historia, no de memoria.

- 1 Coloca K centros al azar.** Como yo pedí $K=3$, el algoritmo lanza 3 puntos cualquiera sobre el plano horas-promedio.
- 2 Asigna cada estudiante al centro más cercano.** Calcula la distancia euclidiana (el teorema de Pitágoras de toda la vida) de cada punto a los 3 centros y lo pinta del color del más cercano.
- 3 Mueve cada centro al promedio de su grupo.** De ahí viene el nombre: *K medias*. El centro se recoloca en el punto medio de los estudiantes que le tocaron.
- 4 Repite 2 y 3 hasta que los centros dejen de moverse.** Cuando ya nadie cambia de grupo, el algoritmo terminó y esos centros finales son los centroides.

Los tres grupos que encontré

Los números 0, 1 y 2 los puso el algoritmo; los nombres los puse yo leyendo los centroides.

Grupo 0 · Bajo rendimiento

centroide: 5.50 h ·
promedio 6.05

Menos de 10 horas semanales y notas cercanas a 6. Son los que necesitan refuerzo y acompañamiento.

Elena, Tomás, Valeria, Martín,
Lucía, Gabriela

Grupo 1 · Rendimiento medio

centroide: 13.50 h ·
promedio 7.92

Entre 11 y 16 horas, con promedios de 7.5 a 8.5. Con un poco más de dedicación pasan al grupo alto.

Jorge, Sofía, Andrés, Paula,
Ricardo, Camila

Grupo 2 · Alto rendimiento

centroide: 21.50 h ·
promedio 9.28

19 horas o más y promedios sobre 8.9. Candidatos a tutorías entre pares, becas o investigación.

Ana, Luis, Carla, Diego, María,
Fernando

Casilla por casilla

El número es la posición de la celda en el notebook, contando desde 0 e incluyendo las celdas de texto. Para cada celda de código: qué hace, qué decir y qué debe aparecer abajo.

APERTURA Y DATOS

00

Portada

TEXTO

Título, tu nombre, el objetivo de la tarea y el contexto: una institución educativa quiere analizar a sus estudiantes.

QUÉ DECIR

“El objetivo es aplicar K-Means para descubrir grupos de estudiantes usando solo dos datos: horas de estudio y promedio.”

02

Importar librerías

CÓDIGO

Trae `numpy` para los cálculos, `pandas` para la tabla, `matplotlib` para los gráficos y, de `sklearn`, la clase `KMeans` y la métrica `silhouette_score`. También fija la semilla en 42.

QUÉ DECIR

“Fijo la semilla en 42 para que el resultado sea siempre el mismo; si no, K-Means empieza en puntos aleatorios distintos cada vez.”

Salida: “Librerías importadas correctamente”.

04

Crear el DataFrame

CÓDIGO

Un diccionario con tres listas (nombre, horas, promedio) se convierte en un DataFrame de pandas llamado `df`. Aquí se cumple el punto 1 de la consigna.

QUÉ DECIR

“Este es el conjunto de datos: 18 estudiantes inventados, cada fila es una persona y cada columna una variable.”

Salida: tabla de 18 filas × 3 columnas.

05

Exploración rápida

CÓDIGO

`shape`, `info()` y `describe()` : confirma que no hay datos faltantes y muestra los rangos.

QUÉ DECIR

“Las horas van de 3 a 24 con media 13.5, y los promedios de 5.2 a 9.7 con media 7.75. No hay datos vacíos.”

Salida: (18, 3) · sin nulos · tabla de estadísticos.

ANTES DE AGRUPAR

07

Gráfico de dispersión inicial

CÓDIGO

Dibuja los 18 estudiantes todos del mismo color, con su nombre al lado.
Es el punto 2 de la consigna.

QUÉ DECIR

“Todavía no agrupé nada: todos los puntos son iguales. Aun así ya se notan tres nubes separadas, y eso es justo lo que el algoritmo va a confirmar.”

Salida: gráfico con los nombres etiquetados.

08

Observación previa

TEXTO

Deja escrita la hipótesis antes de correr el modelo: se intuyen tres nubes de puntos.

QUÉ DECIR

“Anoto mi hipótesis antes de ejecutar, para después comprobar si el algoritmo coincide conmigo.”

10

Entrenar K-Means

CÓDIGO

Extrae `X` (solo las dos columnas numéricas; el nombre no entra porque K-Means solo trabaja con números), crea `KMeans(n_clusters=3)` y ejecuta `fit`. Es el punto 3 de la consigna.

QUÉ DECIR

“Aquí ocurre todo el aprendizaje. `n_init=10` significa que lo intenta 10 veces desde posiciones iniciales distintas y se queda con el mejor resultado.”

Salida: etiquetas `[2 2 2 2 2 2 1 1 1 1 1 1 0 0 0 0 0]` · inercia 55.432.

12

Agregar la columna Grupo

CÓDIGO

Pega las etiquetas al DataFrame como una columna nueva. Punto 4 de la consigna.

QUÉ DECIR

“Ahora cada estudiante lleva escrito a qué grupo pertenece.”

Salida: la misma tabla con una cuarta columna.

13

Cuántos hay en cada grupo

CÓDIGO

Un `value_counts()` para ver el tamaño de los grupos.

QUÉ DECIR

“Quedaron 6, 6 y 6. Un reparto perfectamente equilibrado, aunque eso el algoritmo no lo busca: le salió así porque los datos son claros.”

Salida: `0 → 6 · 1 → 6 · 2 → 6`.

15

Gráfico con grupos y centroides

CÓDIGO

El mismo diagrama, pero con un color por grupo y los centroides como equis rojas marcadas C0, C1 y C2. Punto 5 de la consigna: estudiantes, grupos y centroides en una sola imagen.

QUÉ DECIR

“Este es el gráfico principal. Cada color es un grupo y cada equis roja es el centro de ese grupo. Fíjense que los centros caen justo en medio de cada nube.”

Salida: gráfico de 3 colores + 3 equis rojas.

17

Tabla de centroides

CÓDIGO

Convierte `cluster_centers_` en una tabla legible, redondeada a dos decimales. Punto 6 de la consigna.

QUÉ DECIR

“Estos son los tres centroides: cada fila son las coordenadas del ‘estudiante promedio’ de ese grupo.”

Salida: $(5.50 \cdot 6.05) - (13.50 \cdot 7.92) - (21.50 \cdot 9.28)$.

18

Centroides en texto

CÓDIGO

Los imprime en una frase para que se lean sin interpretar la tabla.

QUÉ DECIR

“Dicho en palabras: el grupo 0 estudia 5 horas y saca 6; el grupo 2 estudia 21 horas y saca 9.3.”

20

Resumen estadístico por grupo

CÓDIGO

Un `groupby` con cantidad, medias, mínimos y máximos de cada grupo.

QUÉ DECIR

“Aquí veo el rango real de cada grupo, no solo su centro: dónde empieza y dónde termina.”

Salida: tabla de 3 filas, una por grupo.

21

Ponerle nombre a cada grupo

CÓDIGO

Ordena los centroides por horas con `np.argsort` y les asigna el nombre que corresponde. Punto 7 de la consigna. Es la celda más “inteligente” del notebook.

QUÉ DECIR

“No escribí los nombres a mano. Ordeno los centroides de menos a más horas y así, aunque el algoritmo cambie los números, el grupo de menos horas siempre recibe el nombre de bajo rendimiento.”

Salida: los 3 nombres con la lista de integrantes de cada uno.

22

Tabla final ordenada

CÓDIGO

Agrega la columna `Nombre_del_Grupo` y ordena por grupo y horas.

QUÉ DECIR

“Esta es la tabla que le entregaría a la institución: cada estudiante con su perfil escrito en palabras.”

23

Interpretación de los perfiles

TEXTO

La tabla que describe los tres perfiles y qué haría la institución con cada uno.

QUÉ DECIR

“Y la conclusión de fondo: hay una relación directa entre horas de estudio y promedio.”

EL ESTUDIANTE NUEVO

25

Predecir con `predict`

CÓDIGO

Crea a Mateo Andrade (18 horas, promedio 8.7) y le pasa sus datos al modelo ya entrenado. Puntos 8 y 9 de la consigna.

QUÉ DECIR

“Mateo no estaba en los datos de entrenamiento: el modelo nunca lo vio. Aun así lo clasifica al instante.”

Salida: grupo 2 → alto rendimiento.

26

La tabla de distancias

CÓDIGO

Calcula a mano la distancia euclidiana de Mateo a cada centroide con `np.linalg.norm`. Es la prueba de por qué cayó en ese grupo.

QUÉ DECIR

“Esta tabla es la explicación completa: 3.55 al centro alto, 4.57 al medio y 12.78 al bajo. Gana el más cercano, y por eso queda en el grupo alto.”

Salida: 3.548 · 4.568 · 12.778.

27

Mateo en el gráfico

CÓDIGO

Lo dibuja como una estrella dorada, con una línea punteada hacia el centroide que lo capturó.

QUÉ DECIR

“La estrella es Mateo y la línea punteada muestra a qué centro se ‘enganchó’. Está visualmente dentro de la nube de los estudiantes dedicados.”

28

Sumarlo a la tabla

CÓDIGO

Un `concat` para verlo como una fila más, ya con su grupo asignado.

QUÉ DECIR

“Así entraría al sistema de la institución: como un registro más, ya clasificado.”

29

Por qué cayó ahí

TEXTO

La explicación escrita que pide el punto 10 de la consigna.

30

Preguntas de análisis a–e

TEXTO

Las cinco respuestas escritas. En la exposición no las leas: están resumidas más abajo en esta guía.

RETO ADICIONAL: K = 2, 3 Y 4

32

Los tres modelos lado a lado

CÓDIGO

Un bucle entrena K-Means con 2, 3 y 4 grupos y dibuja los tres resultados en un mismo panel, con la inercia y la silueta en cada título.

QUÉ DECIR

“Mismo dato, tres particiones distintas. A la izquierda K-Means parte el curso en dos mitades; a la derecha rompe el grupo bajo en dos pedazos pequeños.”

Salida: panel de 3 gráficos.

33

Tabla comparativa

CÓDIGO

Inercia y coeficiente de silueta de cada K, uno junto al otro.

QUÉ DECIR

“La inercia siempre baja al agregar grupos, así que no sirve sola para elegir. La silueta sí: mide qué tan separados quedan, y su máximo está en $K=3$.”

Salida: silueta 0.569 · **0.667** · 0.588.

34

Centroides de cada K

CÓDIGO

Imprime los centros y cuántos estudiantes cayeron en cada uno para los tres modelos.

QUÉ DECIR

“Con $K=4$ aparecen dos grupos de apenas 3 estudiantes: se parte el grupo bajo en uno de 4 horas y otro de 7. Es demasiado fino para servir de algo.”

35

Método del codo y silueta

CÓDIGO

Prueba de $K=1$ hasta $K=8$ y grafica las dos curvas, con una línea roja marcando $K=3$.

QUÉ DECIR

“En la curva izquierda la inercia se desploma hasta 3 y después casi no mejora: ese quiebre es el codo. En la derecha, la silueta hace su pico en 3. Los dos criterios apuntan al mismo número.”

Salida: 2 gráficos + la lista de $K=1$ a 8.

36

Quién quedó dónde con cada K

CÓDIGO

Tabla con las tres asignaciones (K_2 , K_3 , K_4) por estudiante.

QUÉ DECIR

“Aquí se ve, persona por persona, cómo se mueven al cambiar el número de grupos.”

37

Respuesta al reto

TEXTO

Por qué $K=3$ es la mejor opción, con los tres argumentos: codo, silueta y sentido pedagógico. Incluye la nota técnica sobre normalizar con `StandardScaler`.

38

Conclusiones

TEXTO

Las seis conclusiones finales. Con esta celda cierras la exposición.

La comparación, en una tabla

Por si te piden justificar el K elegido sin volver al notebook.

K	INERCIA	SILUETA	QUÉ PASA CON LOS GRUPOS
2	217.81	0.569	Desaparece el grupo medio; queda 9 y 9
3	55.43	0.667	Bajo, medio y alto: 6, 6 y 6
4	40.53	0.588	El grupo bajo se parte en dos de 3

Si te preguntan

Las cinco preguntas de la consigna, más las tres que suelen caer de sorpresa. Respuestas cortas, para decirlas de corrido.

¿Qué representa un centroide?

Es el punto promedio de todos los estudiantes de un grupo: la media de sus horas y la media de sus notas. Funciona como el “estudiante típico” del grupo. Ojo: no es una persona real, es un punto calculado.

¿Qué significan el 0, el 1 y el 2?

Son solo nombres de grupo, no calificaciones ni un orden. El 0 no es peor que el 2. Si cambio la semilla, los mismos estudiantes pueden quedar juntos pero con otro número. Por eso yo los interpreté mirando sus centroides y les puse nombre.

¿Cómo decide a qué grupo va un estudiante nuevo?

Mide la distancia euclidiana de ese punto a cada uno de los tres centroides y lo manda al más cercano. Nada más. No mira etiquetas ni sabe cuál es la respuesta “correcta”.

¿Para qué le sirve esto a la institución?

Para detectar a tiempo a los estudiantes en riesgo, armar tutorías entre pares juntando el grupo alto con el bajo, dar apoyos distintos a cada perfil en vez de uno solo para todos, e identificar candidatos a becas o investigación.

¿Y si cambio a 2 o a 4 grupos?

Con 2 se pierde el grupo medio, que es justamente el más interesante para intervenir. Con 4 se parte el grupo bajo en dos pedazos de 3 estudiantes muy parecidos entre sí: más detalle, pero menos útil. Lo comprobé con la silueta: 0.569, 0.667 y 0.588.

¿Es aprendizaje supervisado o no supervisado?

No supervisado. Nunca le dije al algoritmo quién era buen o mal estudiante: los grupos los descubrió solo, a partir de la forma de los datos.

¿Por qué `random_state=42` ?

Porque K-Means arranca con centros aleatorios. Fijar la semilla hace que cualquiera que ejecute mi notebook obtenga exactamente los mismos grupos y los mismos números que estoy mostrando.

¿No deberías haber normalizado los datos?

Sí, sería la mejora natural, y está anotada en el notebook. Las horas van de 3 a 24 y los promedios de 5.2 a 9.7, así que las horas pesan más en la distancia. Con datos tan separados como estos el resultado no cambia, pero con variables de escalas muy distintas usaría `StandardScaler` antes de aplicar K-Means.

No digas / mejor di

Cuatro deslices que delatan que no entendiste el algoritmo.

ETIQUETAS

~~“El grupo 0 es el peor y el 2 el mejor.”~~

“Los números son etiquetas arbitrarias; el orden lo puse yo al leer los centroides.”

CENTROIDE

~~“El centroide es el mejor estudiante del grupo.”~~

“El centroide es el promedio del grupo; puede no coincidir con ningún estudiante real.”

PREDICCIÓN

~~“El modelo adivina la nota de Mateo.”~~

“El modelo no predice notas: solo dice a qué grupo se parece más, midiendo distancias.”

ELEGIR K

~~“Elegí 3 porque la inercia era más baja.”~~

“La inercia siempre baja al añadir grupos; elegí 3 por el codo y porque la silueta es máxima ahí.”

Cierre sugerido: “En resumen, K-Means encontró solo tres perfiles de estudiante, los centroides me permitieron ponerles nombre, y el modelo ya sirve para clasificar a cualquier estudiante nuevo en el momento en que se matricula.”